Московский государственный технический университет им. Н. Э. Баумана

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №1

«Технологии разведочного анализа и обработки данных.»

Вариант № 26

Выполнил:
Ахмеров Д.И.
группа ИУ5Ц-83Б

Дата: 28.04.2026

Подпись:

Проверил:
Гапанюк Ю.Е.

Дата:

Подпись:

Москва, 2026 г.

Задание:

Номер варианта: **26**

Номер задачи: **4**

Номер набора данных, указанного в задаче: **2** (https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_wine.html#sklearn.datasets.load_wine)

Для студентов групп ИУ5-63Б, ИУ5Ц-83Б - для произвольной колонки данных построить график "Ящик с усами (boxplot)".

Задача №4.

Для заданного набора данных постройте основные графики, входящие в этап разведочного анализа данных. В случае наличия пропусков в данных удалите строки или колонки, содержащие пропуски. Какие графики Вы построили и почему? Какие выводы о наборе данных Вы можете сделать на основании построенных графиков?

Ход выполнения

Разведочный анализ данных Wine Dataset

Тема: построение основных графиков разведочного анализа данных (EDA).
Набор данных: `load_wine` из библиотеки `sklearn.datasets`.

Датасет Wine — это классический набор данных для задачи многоклассовой классификации. В нём 178 объектов, 13 числовых признаков и 3 класса вина.

В работе также искусственно добавлены пропуски, так как по условию, если пропусков нет, их можно создать самостоятельно. Затем строки с пропусками удаляются.

1. Импорт библиотек

[17]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.datasets import load_wine

sns.set(style='whitegrid')
plt.rcParams['figure.figsize'] = (8, 5)
```

2. Загрузка набора данных

[18]:
```
wine = load_wine()

df = pd.DataFrame(wine.data, columns=wine.feature_names)
df['target'] = wine.target

print('Размер датасета:', df.shape)
df.head()
```

```
Размер датасета: (178, 14)
```

[18]:

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols	proanthocyanins	color_intensity	hue	od280/od
0	14.23	1.71	2.43	15.6	127.0	2.80	3.06	0.28	2.29	5.64	1.04	
1	13.20	1.78	2.14	11.2	100.0	2.65	2.76	0.26	1.28	4.38	1.05	
2	13.16	2.36	2.67	18.6	101.0	2.80	3.24	0.30	2.81	5.68	1.03	
3	14.37	1.95	2.50	16.8	113.0	3.85	3.49	0.24	2.18	7.80	0.86	
4	13.24	2.59	2.87	21.0	118.0	2.80	2.69	0.39	1.82	4.32	1.04	

3. Общая информация о данных

[19]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 178 entries, 0 to 177
Data columns (total 14 columns):
 #   Column                        Non-Null Count  Dtype
---  ------                        --------------  -----
 0   alcohol                       178 non-null    float64
 1   malic_acid                    178 non-null    float64
 2   ash                           178 non-null    float64
 3   alcalinity_of_ash             178 non-null    float64
 4   magnesium                     178 non-null    float64
 5   total_phenols                 178 non-null    float64
 6   flavanoids                    178 non-null    float64
 7   nonflavanoid_phenols          178 non-null    float64
 8   proanthocyanins               178 non-null    float64
 9   color_intensity               178 non-null    float64
 10  hue                           178 non-null    float64
 11  od280/od315_of_diluted_wines  178 non-null    float64
 12  proline                       178 non-null    float64
 13  target                        178 non-null    int64
dtypes: float64(13), int64(1)
memory usage: 19.6 KB
```

[20]:
```
df.describe().T
```

[20]:

	count	mean	std	min	25%	50%	75%	max
alcohol	178.0	13.000618	0.811827	11.03	12.3625	13.050	13.6775	14.83
malic_acid	178.0	2.336348	1.117146	0.74	1.6025	1.865	3.0825	5.80
ash	178.0	2.366517	0.274344	1.36	2.2100	2.360	2.5575	3.23
alcalinity_of_ash	178.0	19.494944	3.339564	10.60	17.2000	19.500	21.5000	30.00
magnesium	178.0	99.741573	14.282484	70.00	88.0000	98.000	107.0000	162.00
total_phenols	178.0	2.295112	0.625851	0.98	1.7425	2.355	2.8000	3.88
flavanoids	178.0	2.029270	0.998859	0.34	1.2050	2.135	2.8750	5.08
nonflavanoid_phenols	178.0	0.361854	0.124453	0.13	0.2700	0.340	0.4375	0.66
proanthocyanins	178.0	1.590899	0.572359	0.41	1.2500	1.555	1.9500	3.58
color_intensity	178.0	5.058090	2.318286	1.28	3.2200	4.690	6.2000	13.00
hue	178.0	0.957449	0.228572	0.48	0.7825	0.965	1.1200	1.71
od280/od315_of_diluted_wines	178.0	2.611685	0.709990	1.27	1.9375	2.780	3.1700	4.00
proline	178.0	746.893258	314.907474	278.00	500.5000	673.500	985.0000	1680.00
target	178.0	0.938202	0.775035	0.00	0.0000	1.000	2.0000	2.00

4. Проверка пропусков

Изначально в датасете Wine пропуски отсутствуют, поэтому добавим их искусственно в несколько признаков.

[21]:
```
df.isnull().sum()
```

[21]:
```
alcohol                         0
malic_acid                      0
ash                             0
alcalinity_of_ash               0
magnesium                       0
total_phenols                   0
flavanoids                      0
nonflavanoid_phenols            0
proanthocyanins                 0
color_intensity                 0
hue                             0
od280/od315_of_diluted_wines    0
proline                         0
target                          0
dtype: int64
```

5. Искусственное добавление пропусков

[22]:
```
np.random.seed(42)

# Добавляем пропуски примерно в 5% строк для двух признаков
missing_alcohol = np.random.choice(df.index, size=int(len(df) * 0.05), replace=False)
missing_magnesium = np.random.choice(df.index, size=int(len(df) * 0.05), replace=False)

df.loc[missing_alcohol, 'alcohol'] = np.nan
df.loc[missing_magnesium, 'magnesium'] = np.nan

print('Количество пропусков после искусственного добавления:')
df.isnull().sum()
```

```
Количество пропусков после искусственного добавления:
```

[22]:
```
alcohol                         8
malic_acid                      0
ash                             0
alcalinity_of_ash               0
magnesium                       8
total_phenols                   0
flavanoids                      0
nonflavanoid_phenols            0
proanthocyanins                 0
color_intensity                 0
hue                             0
od280/od315_of_diluted_wines    0
proline                         0
target                          0
dtype: int64
```

6. Удаление строк с пропусками

По условию задания при наличии пропусков строки или колонки с пропусками необходимо удалить. В данной работе удаляются строки, содержащие пропуски.

[23]:
```
df_clean = df.dropna()

print('Размер данных до удаления пропусков:', df.shape)
print('Размер данных после удаления пропусков:', df_clean.shape)
print('Оставшиеся пропуски:')
print(df_clean.isnull().sum().sum())
```

```
Размер данных до удаления пропусков: (178, 14)
Размер данных после удаления пропусков: (162, 14)
Оставшиеся пропуски:
0
```

7. Распределение классов target

График показывает, сколько объектов относится к каждому классу вина.

[24]:
```
plt.figure(figsize=(7, 5))
sns.countplot(data=df_clean, x='target')
plt.title('Распределение объектов по классам')
plt.xlabel('Класс вина')
plt.ylabel('Количество объектов')
plt.show()
```

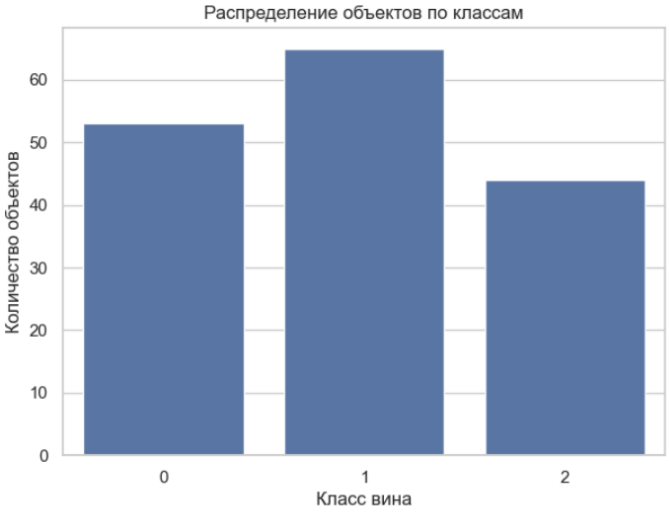

8. Гистограммы признаков

Гистограммы используются для анализа распределения числовых признаков: можно увидеть, какие признаки распределены равномерно, какие имеют асимметрию, а где встречаются редкие значения.

[25]:
```
df_clean.hist(figsize=(16, 12), bins=15)
plt.suptitle('Гистограммы числовых признаков', fontsize=16)
plt.tight_layout()
plt.show()
```

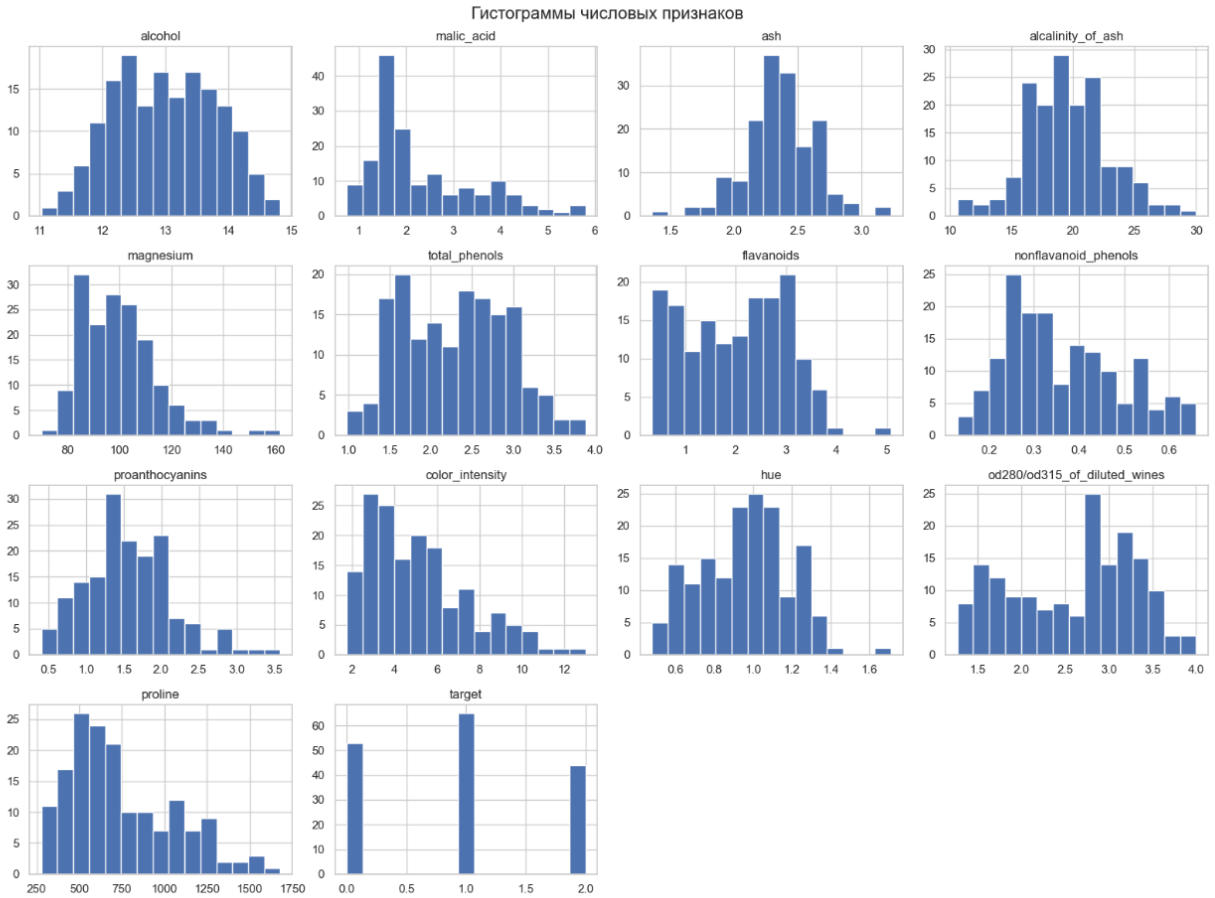

9. Boxplot — «ящик с усами»

Для студентов групп ИУ5-63Б, ИУ5Ц-83Б нужно построить boxplot для произвольной колонки. Построим график для признака `alcohol`.

Boxplot позволяет увидеть медиану, межквартильный размах и возможные выбросы.

[26]:
```
plt.figure(figsize=(8, 5))
sns.boxplot(x=df_clean['alcohol'])
plt.title('Boxplot для признака alcohol')
plt.xlabel('Alcohol')
plt.show()
```

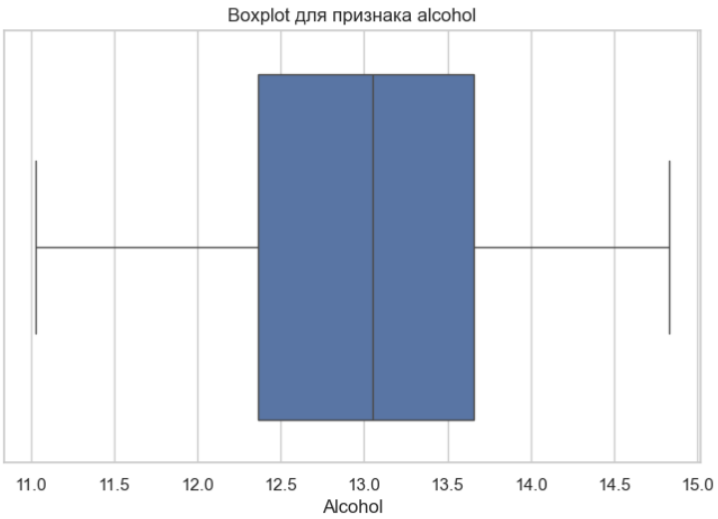

10. Boxplot признака alcohol по классам

Этот график показывает, отличается ли содержание алкоголя у разных классов вина.

[27]:
```
plt.figure(figsize=(8, 5))
sns.boxplot(data=df_clean, x='target', y='alcohol')
plt.title('Содержание alcohol по классам вина')
plt.xlabel('Класс вина')
plt.ylabel('Alcohol')
plt.show()
```

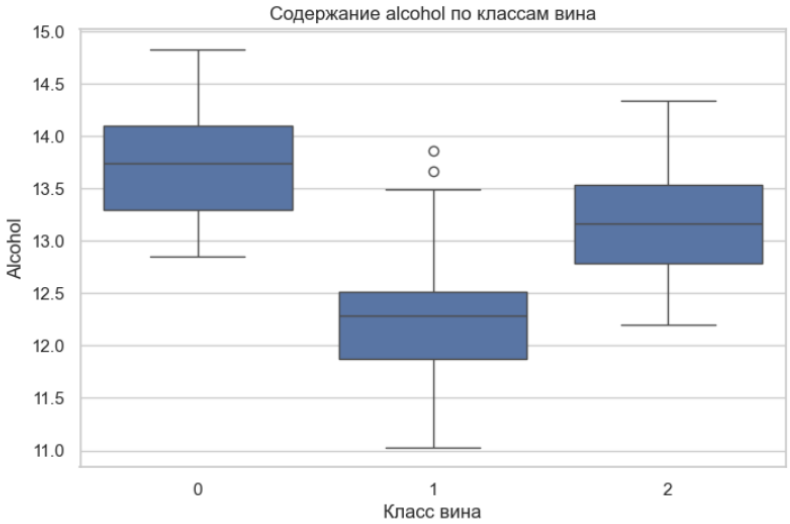

11. Корреляционная матрица

Корреляционная матрица показывает взаимосвязи между числовыми признаками. Чем ближе значение корреляции к 1 или -1, тем сильнее связь.

[28]:
```
plt.figure(figsize=(14, 10))
corr = df_clean.corr()
sns.heatmap(corr, cmap='coolwarm', annot=True, linewidths=0.5)
plt.title('Корреляционная матрица признаков')
plt.show()
```

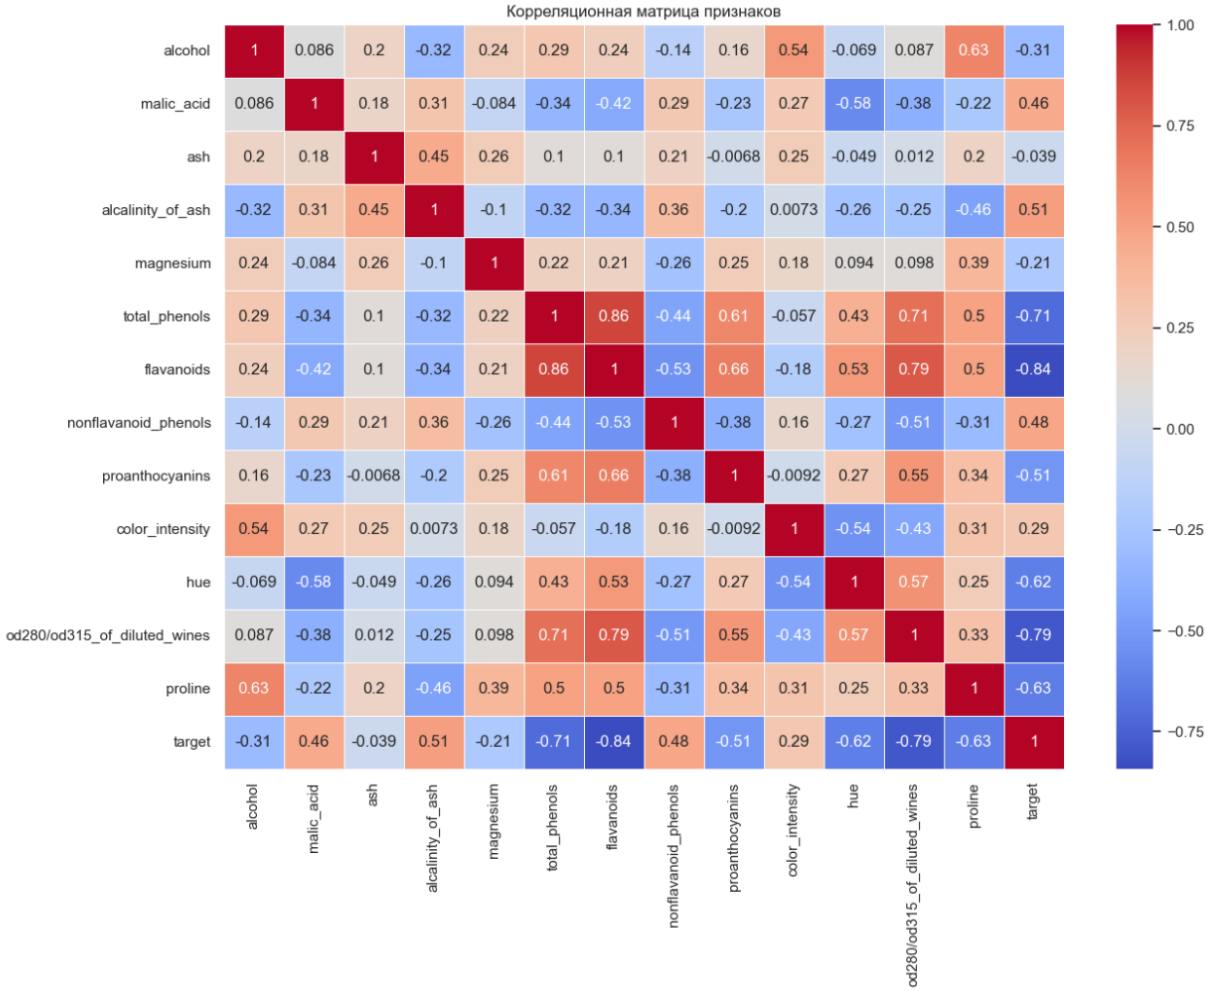

12. Топ корреляций между признаками

[29]:
```
corr_pairs = corr.abs().unstack().sort_values(ascending=False)
corr_pairs = corr_pairs[corr_pairs < 1]
corr_pairs.head(10)
```

[29]:
```
flavanoids                    total_phenols                 0.858081
total_phenols                 flavanoids                    0.858081
target                        flavanoids                    0.842951
flavanoids                    target                        0.842951
od280/od315_of_diluted_wines  target                        0.793855
target                        od280/od315_of_diluted_wines  0.793855
flavanoids                    od280/od315_of_diluted_wines  0.792791
od280/od315_of_diluted_wines  flavanoids                    0.792791
total_phenols                 target                        0.711533
target                        total_phenols                 0.711533
dtype: float64
```

13. Диаграмма рассеяния

Scatter plot помогает увидеть связь между двумя признаками. Для анализа выбраны `alcohol` и `color_intensity`, так как они часто хорошо разделяют классы вина.

[30]:
```
plt.figure(figsize=(8, 6))
sns.scatterplot(data=df_clean, x='alcohol', y='color_intensity', hue='target', palette='Set1')
plt.title('Связь alcohol и color_intensity')
plt.xlabel('Alcohol')
plt.ylabel('Color intensity')
plt.legend(title='Класс')
plt.show()
```

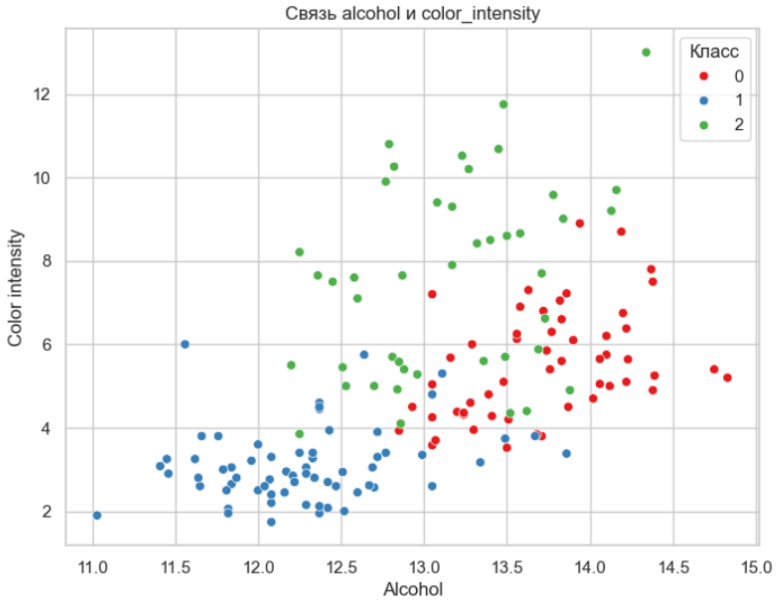

14. Pairplot для нескольких признаков

Pairplot строит попарные графики между выбранными признаками. Он помогает увидеть, насколько хорошо классы разделяются визуально.

[31]:
```
selected_columns = ['alcohol', 'malic_acid', 'flavanoids', 'color_intensity', 'target']
sns.pairplot(df_clean[selected_columns], hue='target', diag_kind='hist')
plt.show()
```

15. Выводы по построенным графикам

В ходе разведочного анализа данных были построены следующие графики:

1. **Countplot распределения классов** — показал количество объектов в каждом классе вина.
2. **Гистограммы признаков** — позволили оценить распределение числовых признаков.
3. **Boxplot для признака alcohol** — помог выявить медиану, разброс и возможные выбросы.
4. **Boxplot alcohol по классам** — показал различия содержания алкоголя между классами.
5. **Корреляционная матрица** — позволила найти признаки, между которыми есть сильные взаимосвязи.
6. **Scatter plot** — показал связь между признаками `alcohol` и `color_intensity`.
7. **Pairplot** — позволил визуально оценить разделимость классов по нескольким признакам.

Основные выводы

- Изначально пропусков в данных нет, поэтому они были добавлены искусственно по условию задания.
- После удаления строк с пропусками размер набора данных уменьшился.
- Классы вина частично различаются по признакам `alcohol`, `color_intensity`, `flavanoids` и другим характеристикам.
- По графикам видно, что некоторые признаки могут быть полезны для классификации вина.
- В данных присутствуют признаки с разным масштабом значений, поэтому перед построением моделей машинного обучения может потребоваться масштабирование.